avito.tech

Москва — 2026

УПРОЩЕНИЕ РАЗМЕТКИ С ПОМОЩЬЮ ЭВРИСТИК

Гилязев Руслан

DS Manager, ML Platform

~~Attention~~ Dataset is all you need*

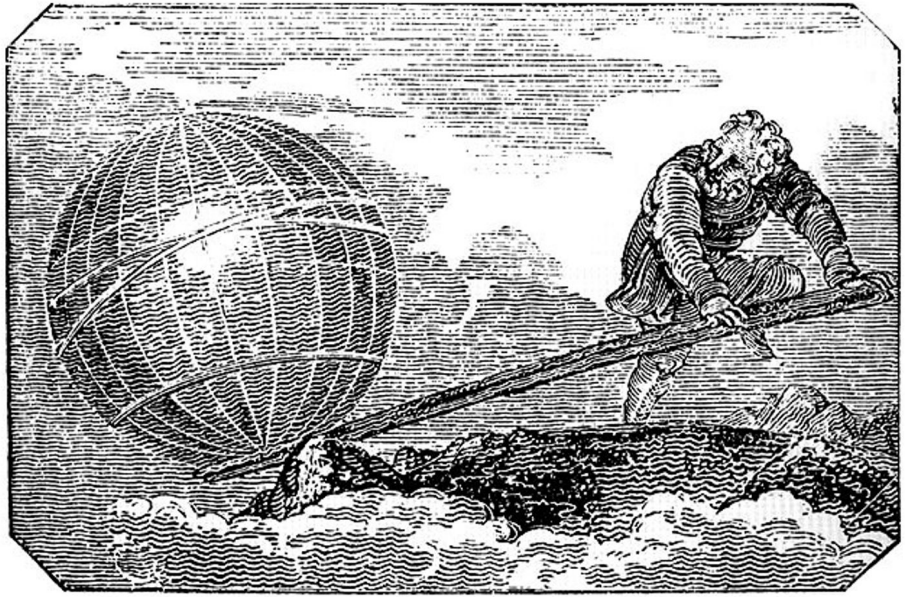

*Attention is all you need – с этой статьи началась эпоха трансформеров в NLP

Эвристики

Что такое эвристики?

Набор правил и методов, не являющийся гарантированно точным или оптимальным, но достаточный для решения поставленной задачи.

Эвристики в контексте разметки

Разметка или выбор кандидатов для разметки автоматически, без асессоров:

- по косвенным признакам
- с привлечением сторонних датасетов / моделей
- с привлечением пользователей продукта

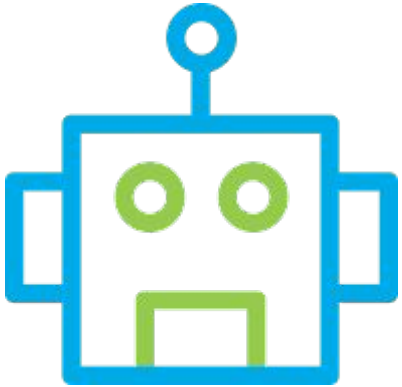

Зачем нужны эвристики

Эвристики – это не альтернатива ручной разметке, а дополнение:

- для отбора кандидатов на разметку
- для быстрого старта

А также:

- разметка асессорами затруднительна

План

- Эвристики
  - Автоматическая разметка с использованием свойств объекта
  - Разметка с использованием сторонних данных
  - Разметка с привлечением пользователей продукта

- Оптимизация ручной разметки
  - Активное обучение
  - Semi-supervised learning

- Заключение

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ СВОЙСТВ ОБЪЕКТА

Пример 1: регулярные выражения

Предсказание категории объявления

Задача: По заголовку объявления предсказываем его категорию.
А что, если категория углубилась недавно и нужно поддержать новые классы?

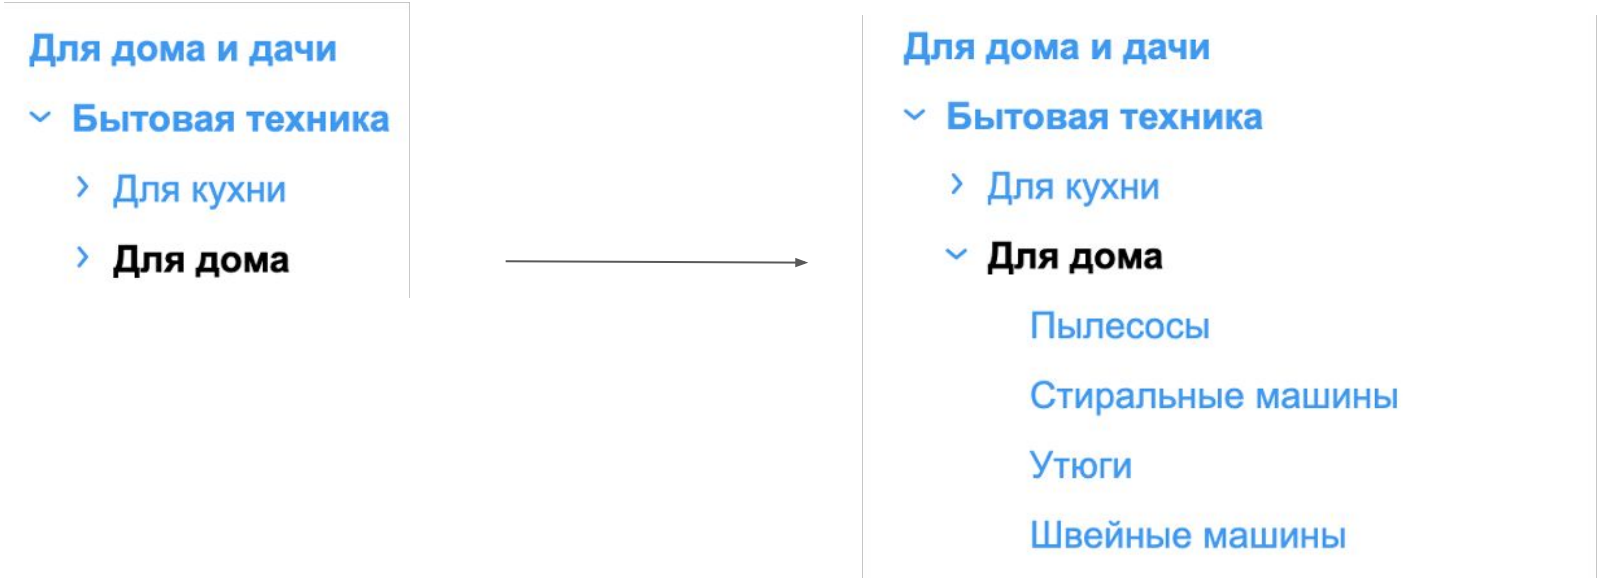

Регулярные выражения

Пылесосы	Стиральные машины	Утюги	Швейная машина
‘пылесос’ ‘dyson’ ‘thomas’	‘стир’ ‘bosch’	‘утюг’ ‘отпариватель’ ‘гладильн’ ‘scarlett’	‘швейн’ ‘оверлок’ ‘вязальн’

Оверлок Leader VS 370D

13 500 ₽

Продаём так как не пользуемся. - 1200 стежков в минуту. - Мин. Длина стежка 4мм, Макс. 7мм. - Механическое управление. - Подсветка. Мощный оверлок. Работает без проблем. Продаём в комплекте с машинкой смотрите объявления.

Юго-Западная 11–15 мин.
Доставка от 1 дня
1 день назад

→ Бытовая техника / Для дома / Швейная машина

Регулярные выражения

- Составляем список регулярных выражений
- Размечаем ими датасет
- На размеченном регулярками датасете обучаем модель

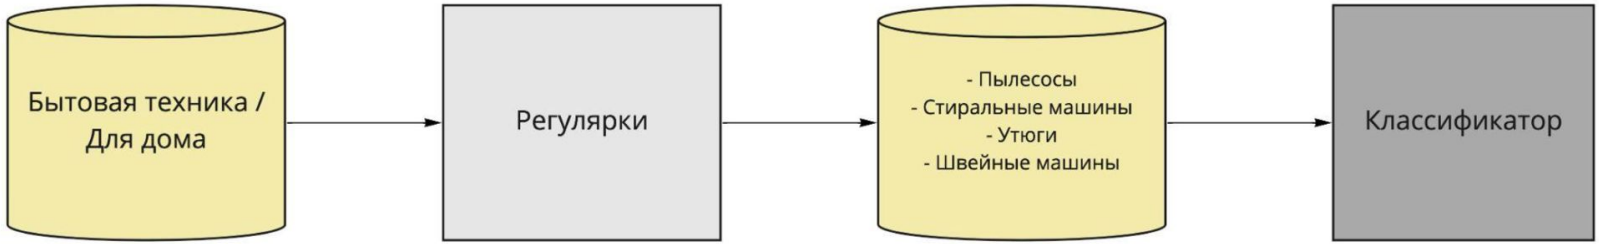

Регулярные выражения

- *Ну мы вот придумали какие-то эвристики. Почему их не подавать на вход модели?*
- *If it looks like a duck, swims like a duck and quacks like a duck, then it probably is a duck. **

Регулярки vs модель на разметке регулярками

Плюсы модели:

- Обобщение информации
  - Больше покрытие - сработает не только там, где сработала регулярка
  - Устойчивость к новым данным / шуму
- Можно учесть уверенность модели в ответе

* duck test: https://en.wikipedia.org/wiki/Duck_test

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ СВОЙСТВ ОБЪЕКТА

Пример 2: заглядываем в будущее

Заглядываем в будущее: антиспам в мессенджере

Задача: построить антиспам-классификатор только по тексту.
Нужно собрать датасет для обучения на спам / не спам.

Можно ли автоматически разметить сообщение:

Заглядываем в будущее: антиспам в мессенджере

Посмотрим на весь чат

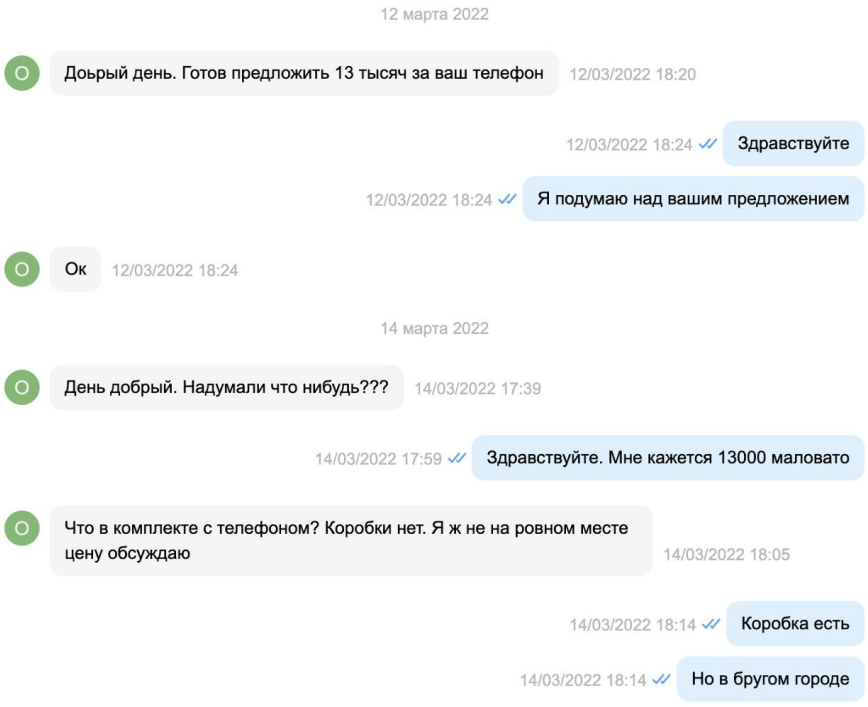

Если диалог состоялся, то вероятность спама минимальна

Заглядываем в будущее: антиспам в мессенджере

Какие эвристики помогут для нахождения спама?

- количество сообщений пользователя
- количество ответов пользователю
- количество жалоб

Is_spam = (сообщений > 5) & (жалоб > 2)

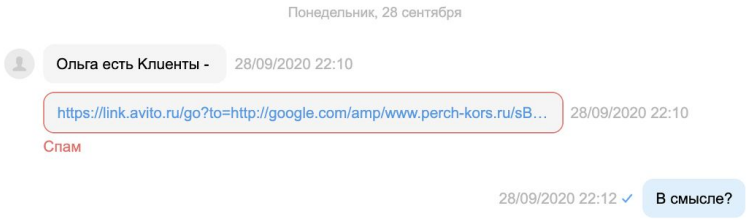

А могли бы мы использовать эти признаки в модели?

Заглядываем в будущее

- Leak detected!

При сборе датасета мы
можем заглядывать в будущее

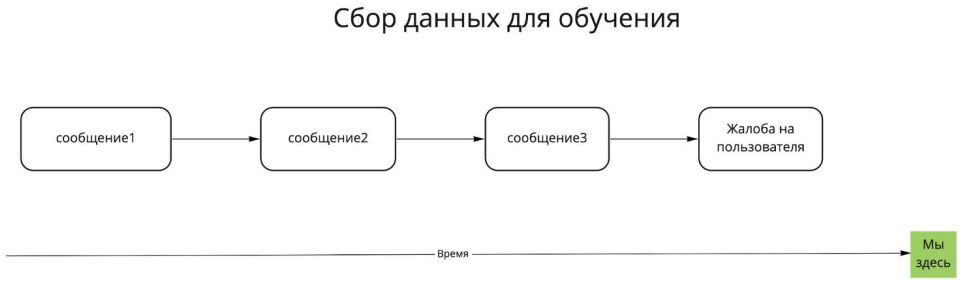

А при применении модели – нет

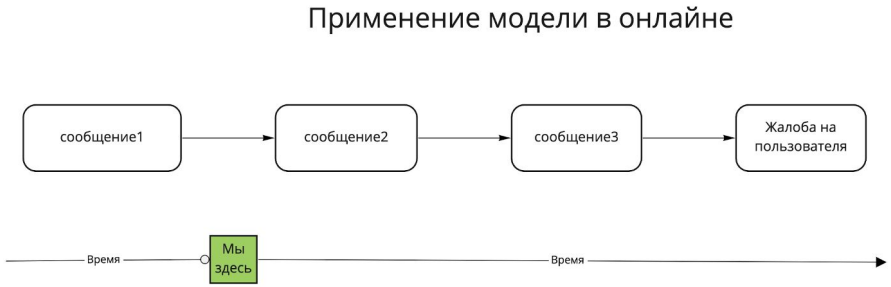

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ СВОЙСТВ ОБЪЕКТА

Пример 3: смотрим на признаки, которые не учитываем в модели

Предсказание состояния авто по фото

Задача: по **фото** авто предсказать, есть ли на нём ржавчина.
Для чего: чтобы учитывать этот признак при предсказании стоимости автомобиля.

Проблема: только меньше 1% авто имеют ржавчины – нужно научиться отбирать кандидатов на разметку

Предсказание состояния авто по фото

Идея: искать в описании объявления фразу “есть ржавчина”.
Фото из этих объявлений с высокой вероятностью имеют ржавчину.

ГАЗ Соболь 2217, 2006

200 000 ₽

180 000 км, 2.3 MT (98 л.с.), микроавтобус, задний, бензин

Продам соболь 7 местный. Двигатель 406 невписан. По кузову есть ржавчина.2006год. Машина на полном ходу. Торг. Обмен.

р-н Левобережный
4 часа назад

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ СВОЙСТВ ОБЪЕКТА

Пример 4: Антифрод

Поиск пользовательского фрода

Задача: по логам пользователя определить попытки взлома аккаунтов
Для чего: не давать мошенникам уводить аккаунты

```
128.32.226.135 - - [14/Apr/2010:03:14:22 +0200] "GET /lectures/mobapp-spring10/img/mobile-platform
-phonegap.png HTTP/1.1" 200 135351 "http://dret.net/lectures/mobapp-spring10/platforms" "Mozilla/5
.0 (Windows; U; Windows NT 5.1; en-US; rv:1.9.2.3) Gecko/20100401 Firefox/3.6.3 (.NET CLR 3.5.3072
9)"
128.32.226.135 - - [14/Apr/2010:03:14:22 +0200] "GET /lectures/mobapp-spring10/img/mobile-platform
-web-based.png HTTP/1.1" 200 91687 "http://dret.net/lectures/mobapp-spring10/platforms" "Mozilla/5
.0 (Windows; U; Windows NT 5.1; en-US; rv:1.9.2.3) Gecko/20100401 Firefox/3.6.3 (.NET CLR 3.5.3072
9)"
```

Проблема: если банить мошенника по конкретной фиче (например, ip-address), мошенник быстро адаптируется.

Решение: строим фичи на действиях пользователя с этого ip-address-а, **не используем** ip-address в качестве фичей, **используем ip как разметку**.

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ ВНЕШНИХ ДАННЫХ

Внешние данные: что такое?

ДАТАСЕТЫ	ImageNet, WiKi, Twitter, ...	
ОБУЧЕННЫЕ МОДЕЛИ	BERT, ResNet, другие модели в компании	

* BERT - **B**idirectional **E**ncoder **R**epresentations from **T**ransformers

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ ВНЕШНИХ ДАННЫХ

Пример 1: уточняем разметку

Внешние данные: уточняем разметку

Задача: сегментация авто на фото.
Проблема: ручное сегментирование – долгий процесс, хочется ускорить.

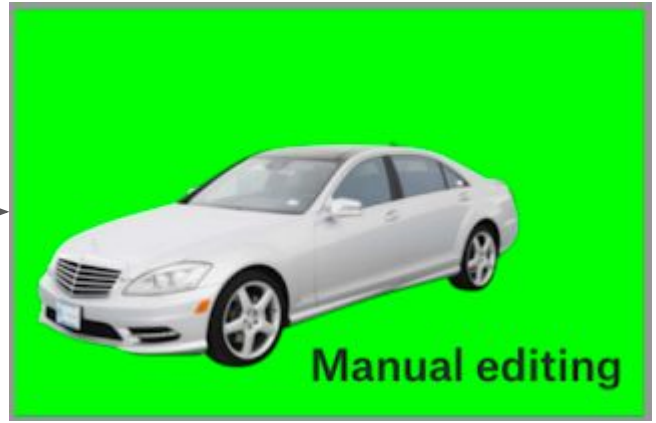

* Carvana Image masking challenge - https://www.kaggle.com/competitions/carvana-image-masking-challenge/overview

Внешние данные: уточняем разметку

Идея: давайте прогонять фото через сегментатор, обученный на другой задаче.

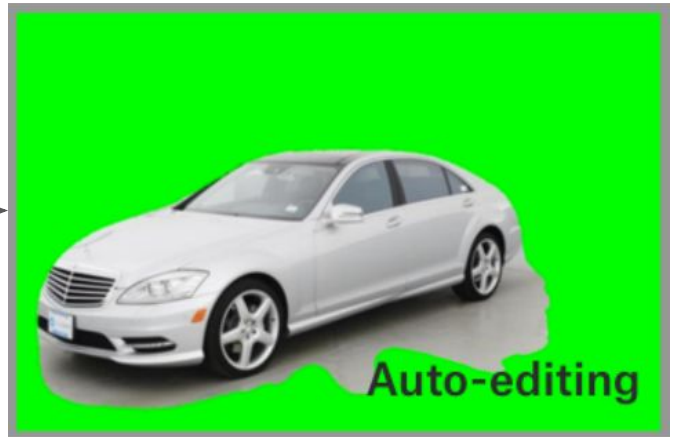

* Carvana Image masking challenge - https://www.kaggle.com/competitions/carvana-image-masking-challenge/overview

Внешние данные: уточняем разметку

Идея: давайте прогонять фото через сегментатор, обученный на другой задаче, а уже потом уточнять разметку!

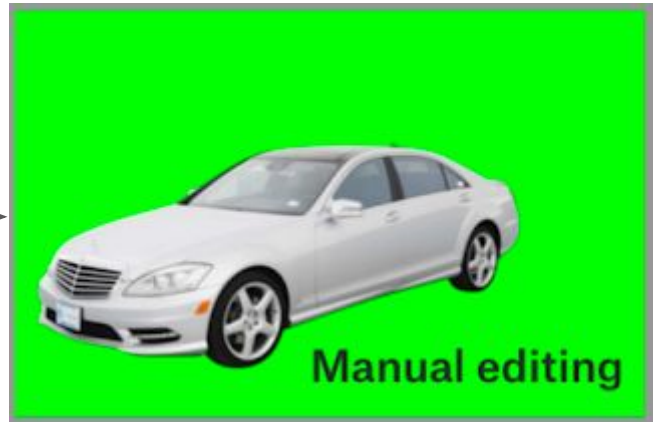

* Carvana Image masking challenge - https://www.kaggle.com/competitions/carvana-image-masking-challenge/overview

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ ВНЕШНИХ ДАННЫХ

Пример 2: берём целые классы

Использование предсказаний другой модели

Задача: по фото квартиры предсказать тип комнаты

- спальня
- ванная
- кухня
- коридор
- балкон
- улица

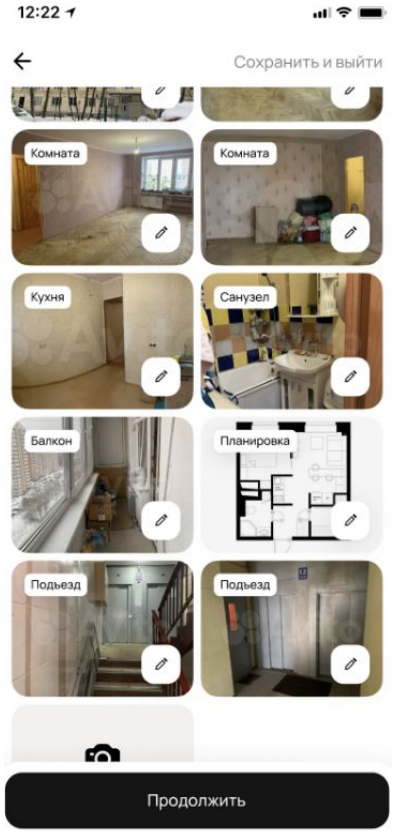

Использование предсказаний другой модели

Хотим предсказывать тип комнаты по фото с классами:

- спальня
- ванная
- кухня
- коридор
- балкон
- улица

Оказалось, что до этого уже делали модель с классами:

- комната
- дом снаружи
- мебель
- автомобиль

РАЗМЕТКА С ИСПОЛЬЗОВАНИЕМ ВНЕШНИХ ДАННЫХ

Пример 3: фильтруем данные

Предсказание состояния авто по фото

Задача: по фото авто предсказать, есть ли на нём ржавчина.

Предсказание состояния авто по фото

Идея: отбираем только фото кузова с помощью модели ракурсов

вид сзади

салон

багажник

дверь

вид спереди

Внешние данные: где искать

- среди моделей / датасетов компании
- kaggle
- google...

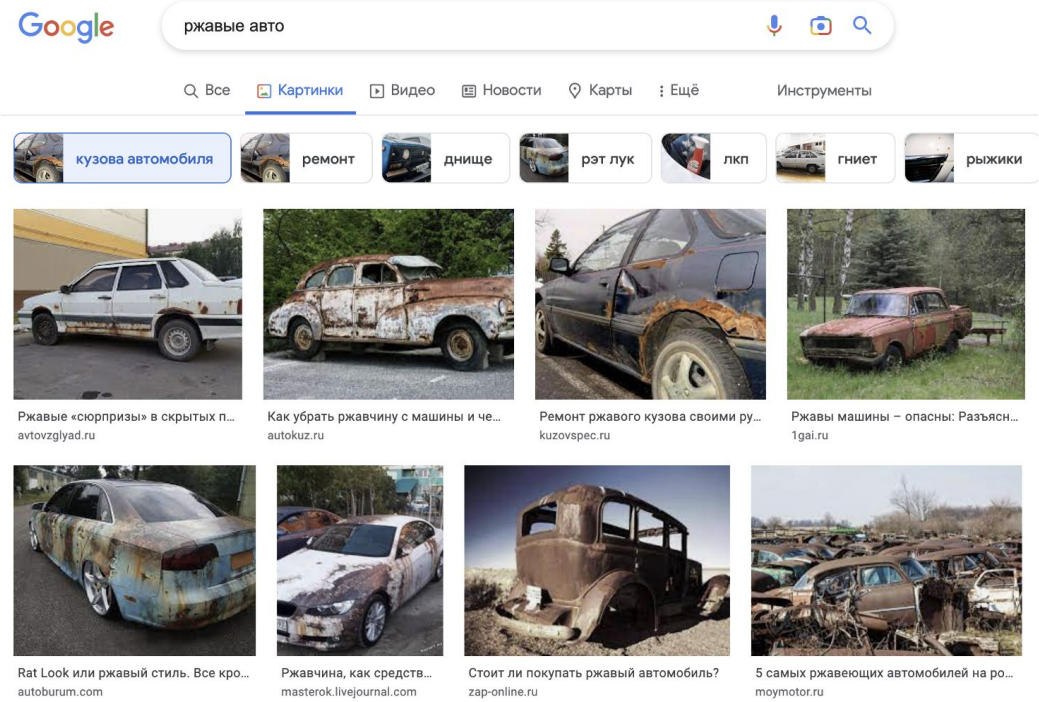

Внешние данные: резюме

ДАТАСЕТЫ

Обучи свою модель на внешних данных

ОБУЧЕННЫЕ МОДЕЛИ

Используй предобученную модель

Разметь моделью внутренние данные

РАЗМЕТКА С ПРИВЛЕЧЕНИЕМ ПОЛЬЗОВАТЕЛЕЙ ПРОДУКТА

Разметка пользователями. Введение

- *Мы же не будем доставлять неудобства пользователям?*
- *Ну почему сразу неудобства... Введите капчу, пожалуйста.*

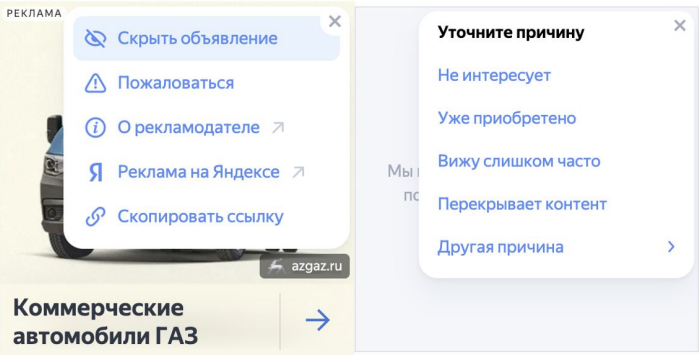

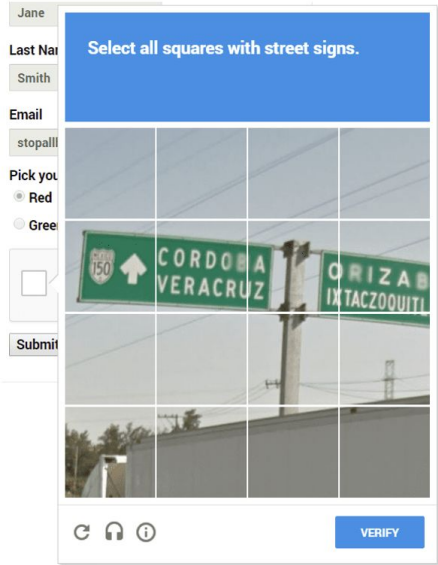

1 рецензия

Разметка пользователями: зачем

Плюсы:

Можно строить продуктовые метрики

Пользователям важно оставлять обратную связь

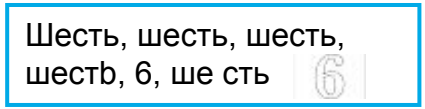

Данные имеют свойства меняться со временем и нужна свежая разметка

РАЗМЕТКА С ПРИВЛЕЧЕНИЕМ ПОЛЬЗОВАТЕЛЕЙ ПРОДУКТА

Пример 1: мессенджер Авито

Это похоже на спам?

- А вы в Авито достаёте пользователей разными пушами?
- *Уведомляем.*
- Назойливое...

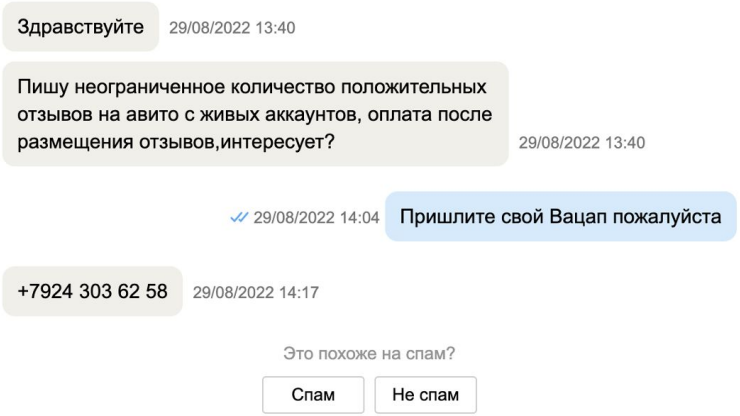

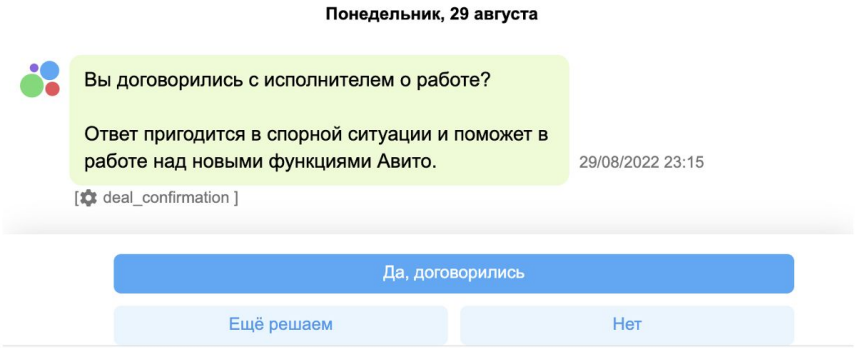

РАЗМЕТКА С ПРИВЛЕЧЕНИЕМ ПОЛЬЗОВАТЕЛЕЙ ПРОДУКТА

Пример 2: не только мессенджер

Разметка с привлечением пользователей

Зловредные пользователи

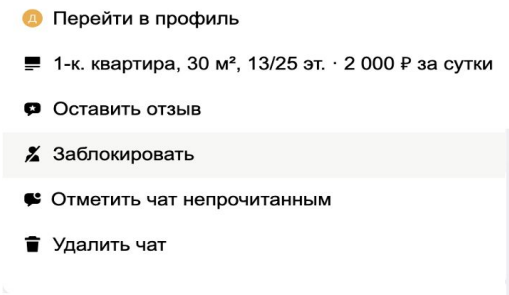

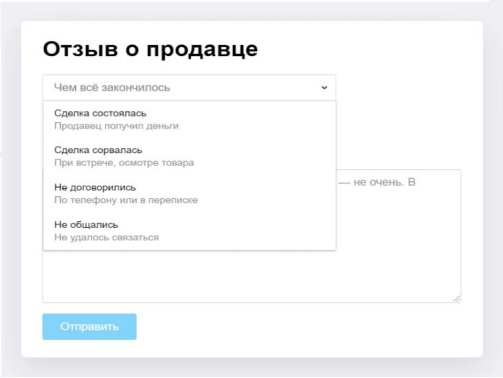

Предсказание факта сделки

Борьба со взломами

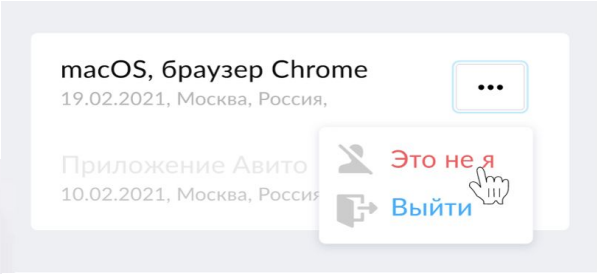

Разметка пользователями: применение

- *А ты знаешь, что дельфины относят тонущих людей к берегу?*
- *А может быть, те, кому повезло меньше, менее болтливы?*

Какие есть проблемы в разметке пользователями?

Разметка пользователями: применение

- *А ты знаешь, что дельфины относят тонущих людей к берегу?*
- *А может быть, те, кому повезло меньше, менее болтливы?*

Такая разметка обычно смещена по таргету, поэтому можно использовать в комбинации с другими эвристиками

Эвристики

Промежуточные итоги

Зачем нужны эвристики

Эвристики – это не альтернатива ручной разметке, а дополнение:

- для отбора кандидатов на разметку
- для быстрого старта

А также:

- разметка асессорами затруднительна

Оптимизация ручной разметки

Активное обучение

Активное обучение: зачем

Задача: разметить как можно меньше примеров, чтобы получить желаемое качество.
Базовый вариант: добавляем по N **случайных** примеров в обучение и смотрим на качество.

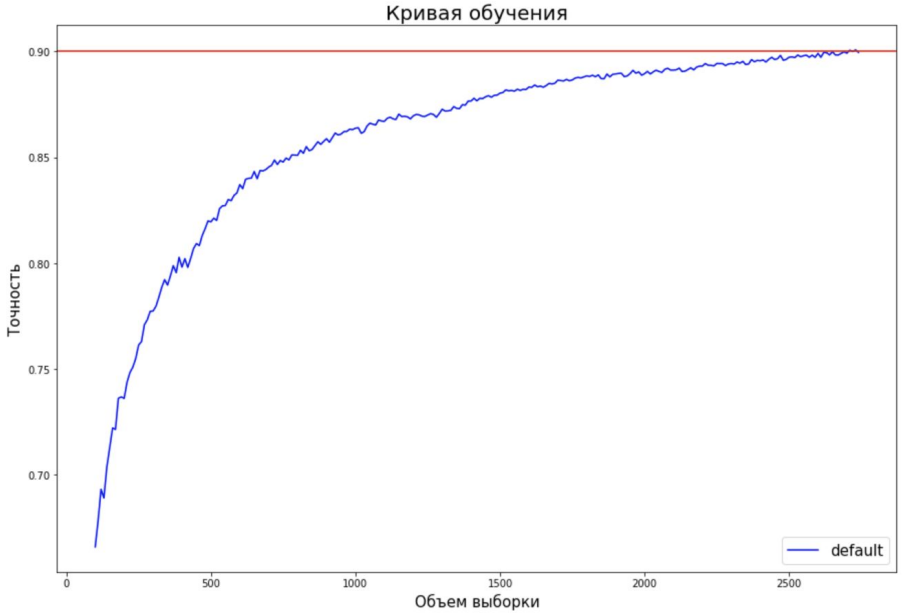

Активное обучение: можно лучше?

Можно ли получить желаемое качество быстрее (разметив меньше данных)?

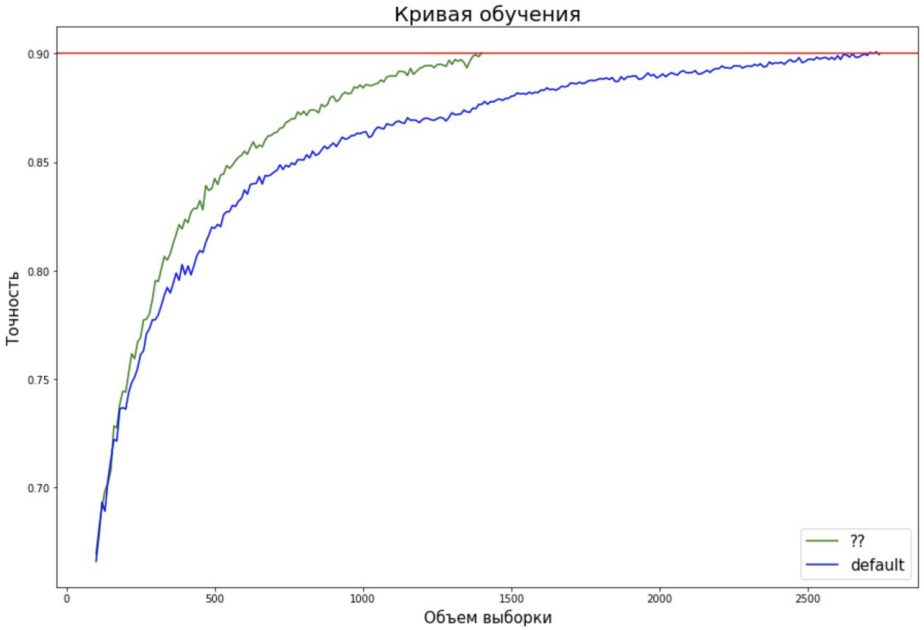

Активное обучение: тяжело в учении...

Идея: есть объекты сложные, есть простые, давайте размечать сложные!

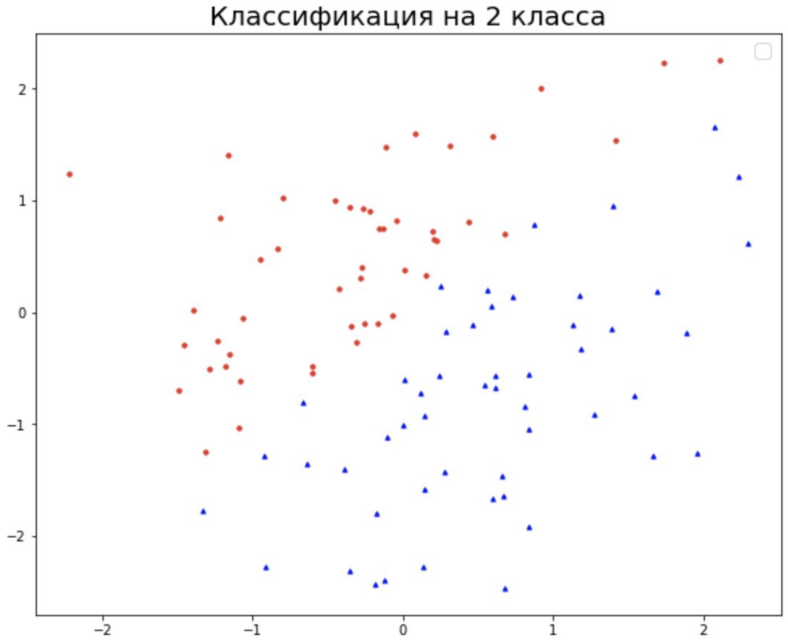

Активное обучение: стратегии

Пассивная стратегия

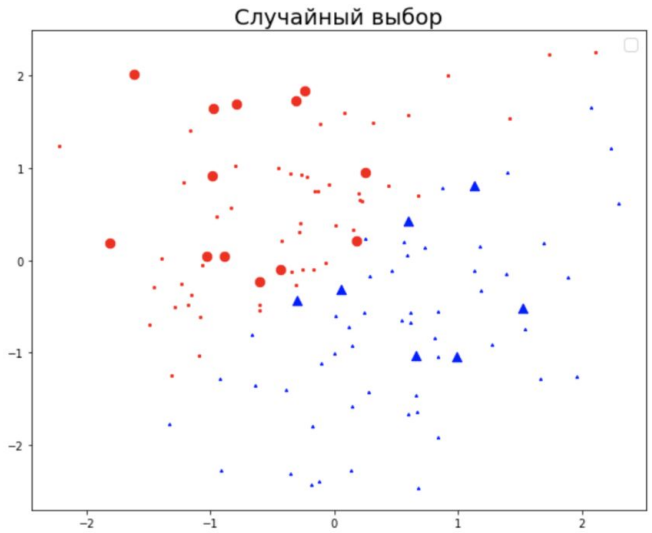

Активная стратегия

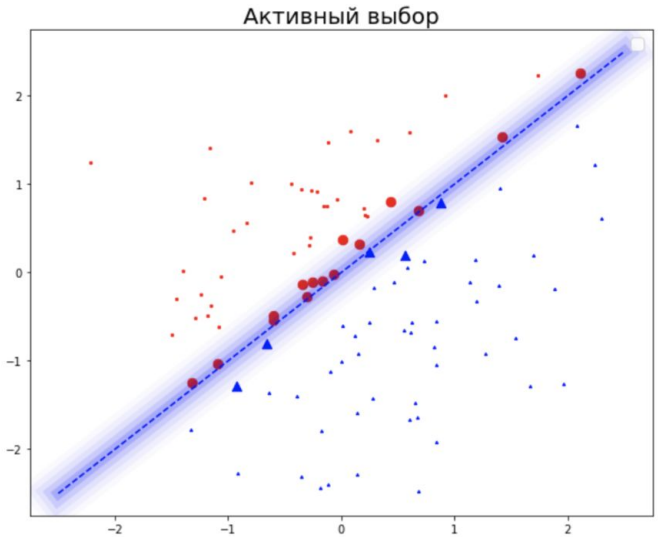

Обычное обучение: пассивный подход

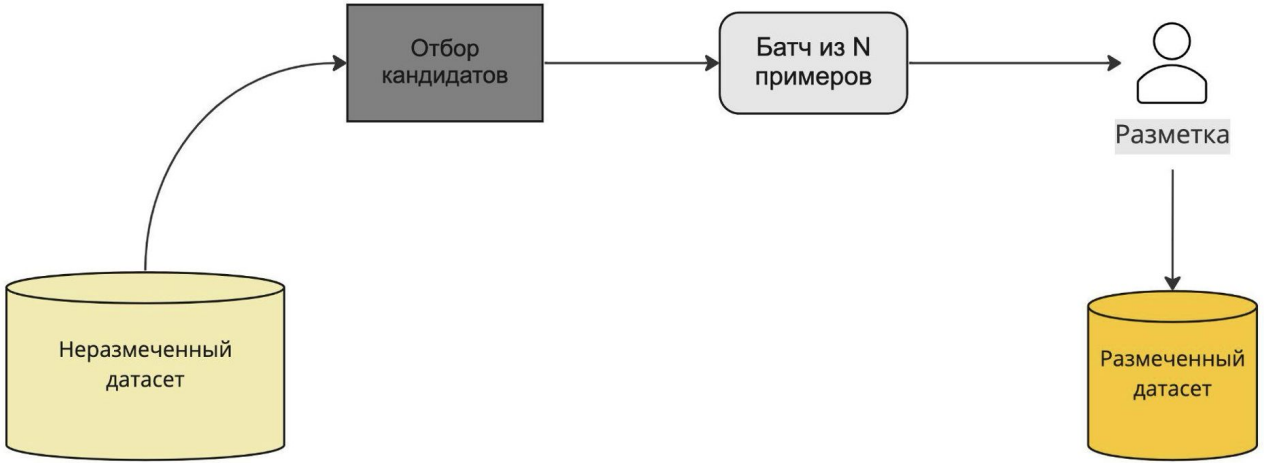

Активное обучение: активный подход

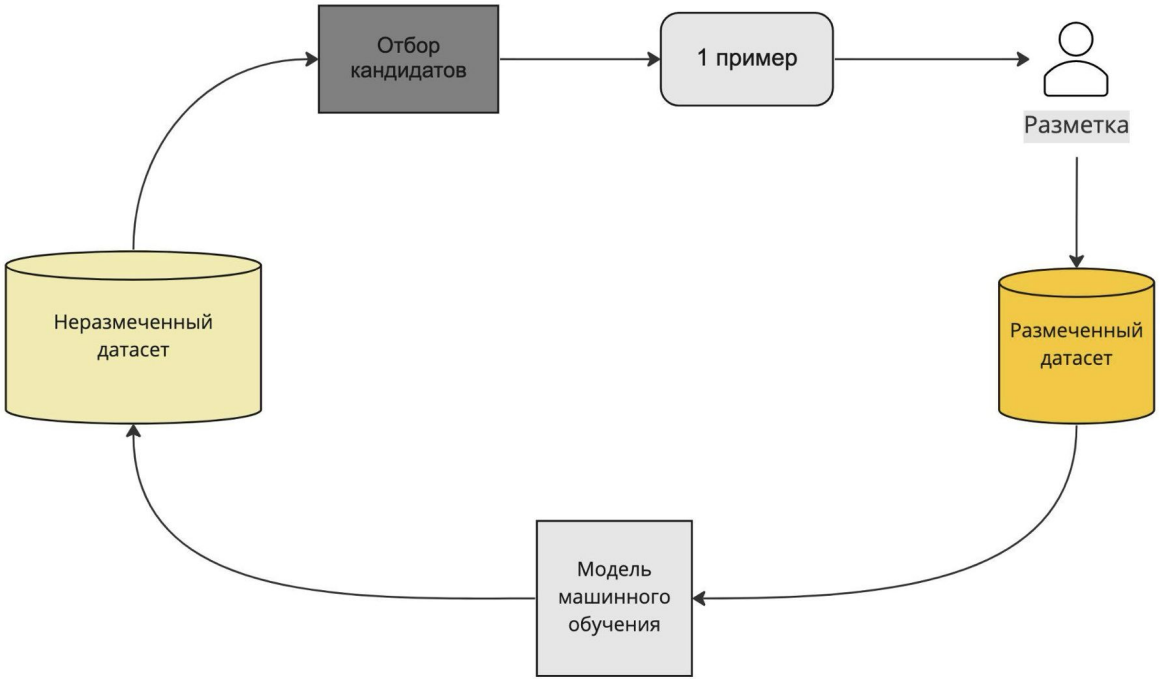

Активное обучение: активный подход

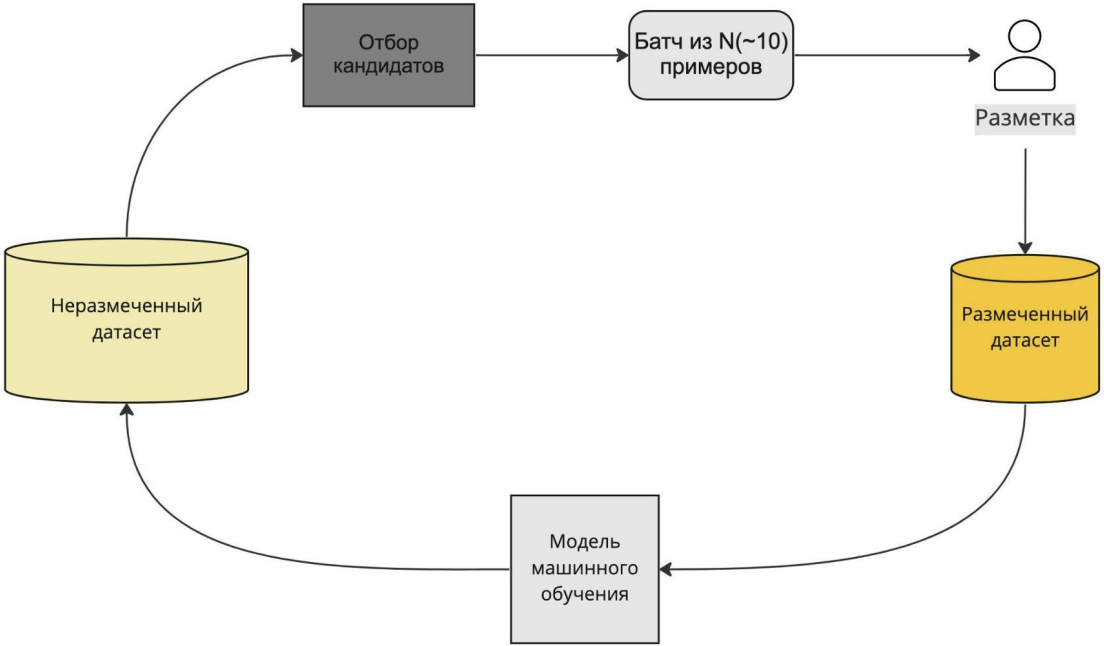

x100

Активное обучение: активный подход

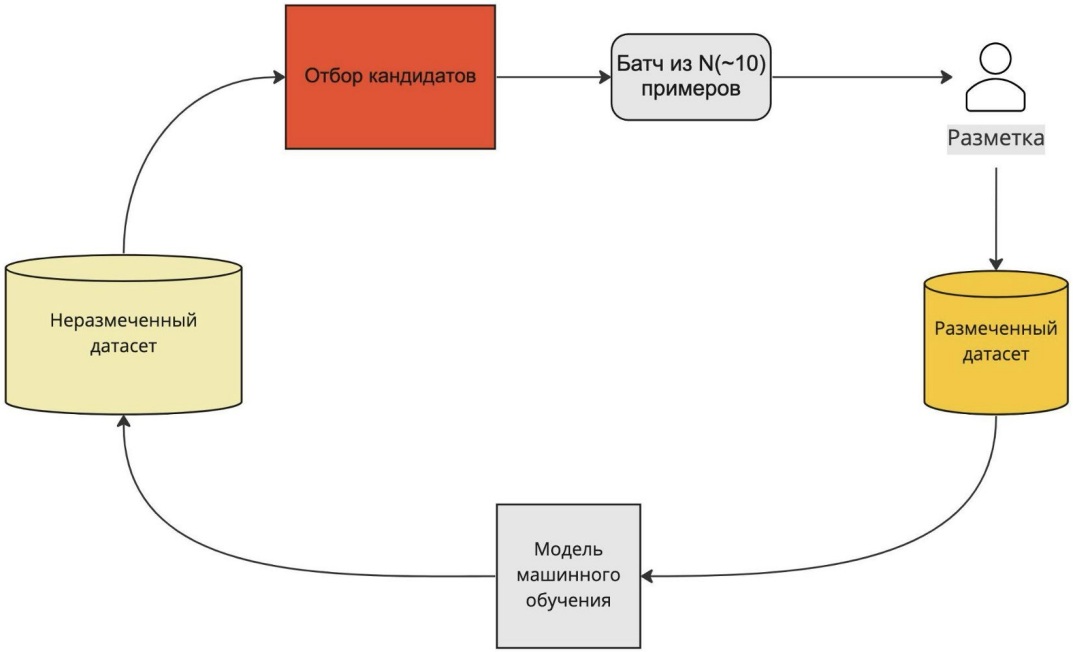

x100

Как отбирать примеры: идея

Выбор по степени неуверенности (Uncertainty) модели

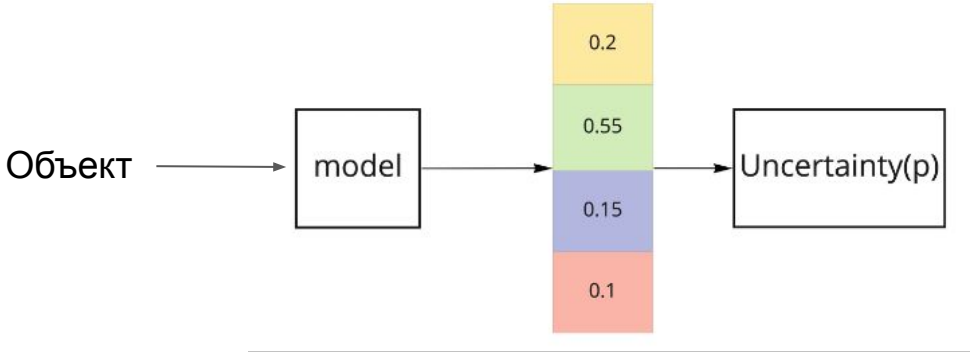

Как отбирать примеры: неуверенность

- Выбор по степени неуверенности (Uncertainty) модели

  Критерии отбора:

  - Максимальная энтропия
  - Минимальный отступ(между топ двумя классами)
  - Минимальная уверенность

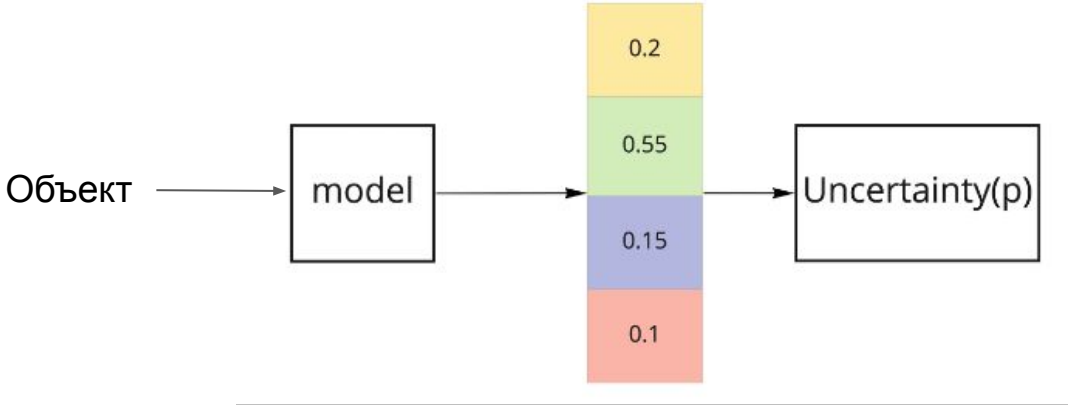

Другие стратегии отбора примеров

- Выбор по степени неуверенности модели
- Отбор комитетом моделей
- Сокращение пространства решений
- Максимизация ожидаемого влияния на модель

https://neerc.ifmo.ru/wiki/index.php?title=Активное_обучение

Активное обучение на практике

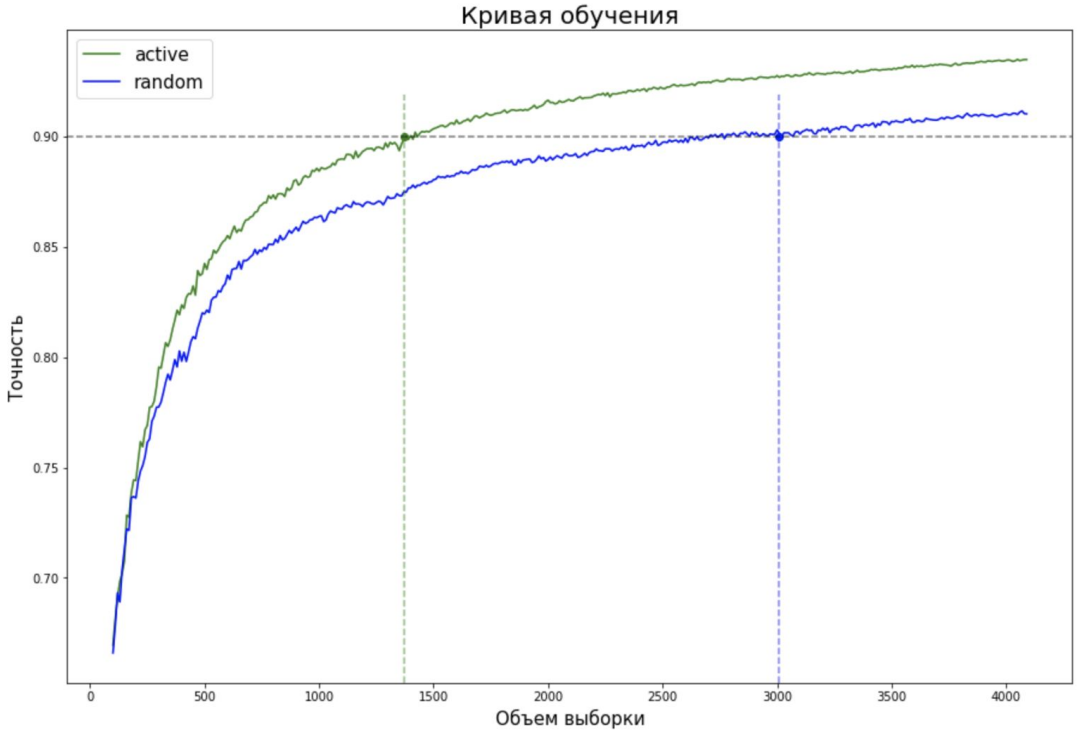

Активное обучение на практике

- Более сложная настройка пайплайна разметки
- Компромисс между размером семпла (батча) и качеством

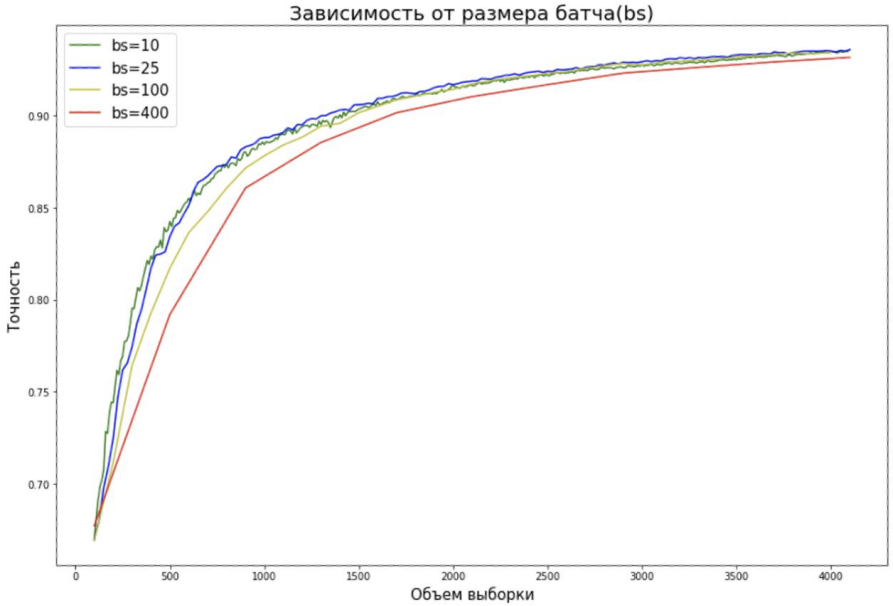

Semi-supervised learning

обучение с частичным привлечением учителя

Псевдолейблинг

Задача: есть небольшой размеченный датасет и большой неразмеченный. Хотим разметить неразмеченный в надежде, что это увеличит качество модели

Подход: берем существующие модели и ответы, в которых модели более уверены, добавляем в датасет. (подход работает на Kaggle, статейка ODS)

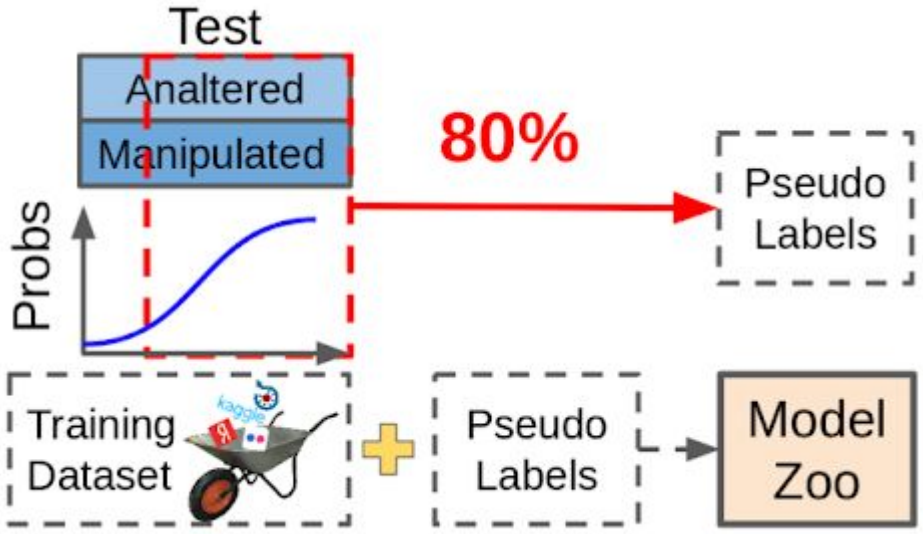

https://habrastorage.org/r/w1560/webt/zu/ck/d1/zuckd1uwalct8d5o-0l3hsum8bi.png

Кластеризация

Задача: может быть так, что размеченных данных нет совсем. Что делать?

Подход: посмотрим как объекты группируются в пространстве фичей. Разметив один объект классом X, можно в класс X взять все близкие.

Модификации: менять алгоритмы кластеризации, инициализировать центры кластеров центрами масс классов, использовать предобученные модели для получения фичей

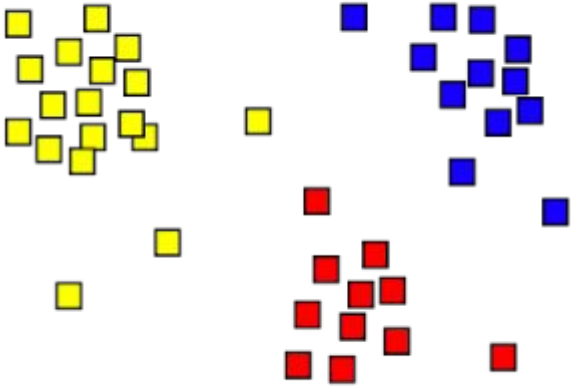

https://upload.wikimedia.org/wikipedia/commons/thumb/c/c8/Cluster-2.svg/440px-Cluster-2.svg.png

Активное обучение: бонус

Проблема: при активном обучении на своих ответах модель “замыкается” на своих ошибках. Ошибки складываются из 2 факторов: фиксированный набор признаков и фиксированная архитектура модели.

Идея:

- Выбираем несколько концептуально разных архитектур моделей
- Обучаем эти модели на независимо сгенерированных фичах
- Примеры для активного обучения модели M1 генерируют модели M2, M3, ..., Mn

Минус: сложнее реализация :)

Более сложные методы по ссылке

Эвристики: итоговый pipeline

Собираем всё вместе

- Эвристики
  - Использование свойств объекта
  - Сторонние датасеты / модели
  - Разметка пользователями
- Активное обучение

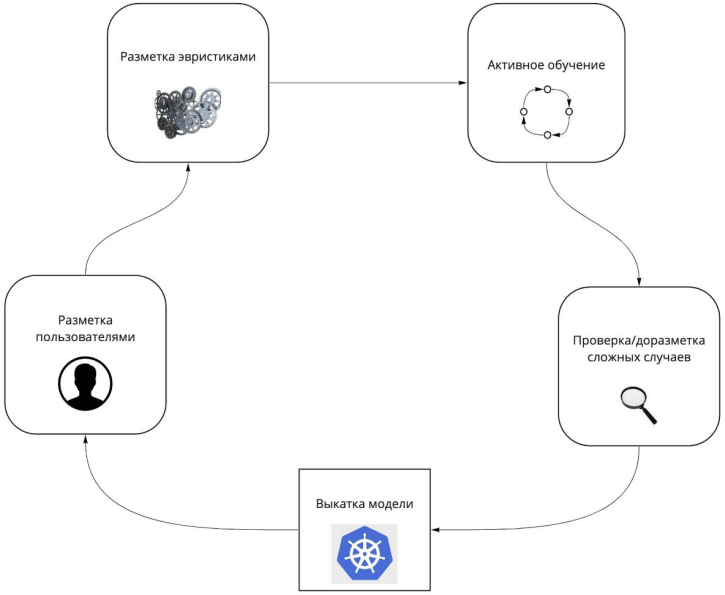

Эвристики

Заключение

Заключение

Эвристики – это не альтернатива ручной разметке, а дополнение:

- для отбора кандидатов на разметку
- для быстрого старта

А также:

- разметка асессорами затруднительна

Активное обучение позволяет уточнить эвристики, ускорить процесс разметки данных.

avito.tech

Москва — 2025

Спасибо!