avito.tech

Москва — 2025

ГЕНЕРАЦИЯ ТЕКСТОВЫХ ДАННЫХ

Степанов Никита

DS Engineer, item2param

План

- Базовые методы генерация в NLP
  - Замена синонимом и обратный перевод
  - Использование представлений слов
  - Контекстные представления
- Введение в LLM
  - Принципы работы
  - Подходы к дообучению LLM
- Разметка с помощью промтов
  - Сравнение разметки llm и краудсорсинга
  - Разметка в авито
- Практическая часть с prompt engineering

Академия
Аналитиков
Авито

Генерация в NLP

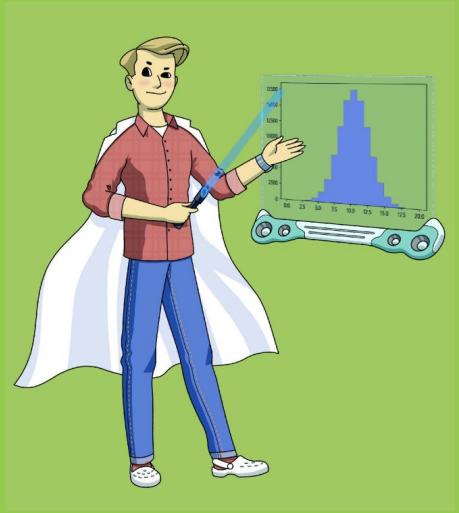

avito.tech

Обратный перевод

Переводим наш текст на другой язык и обратно

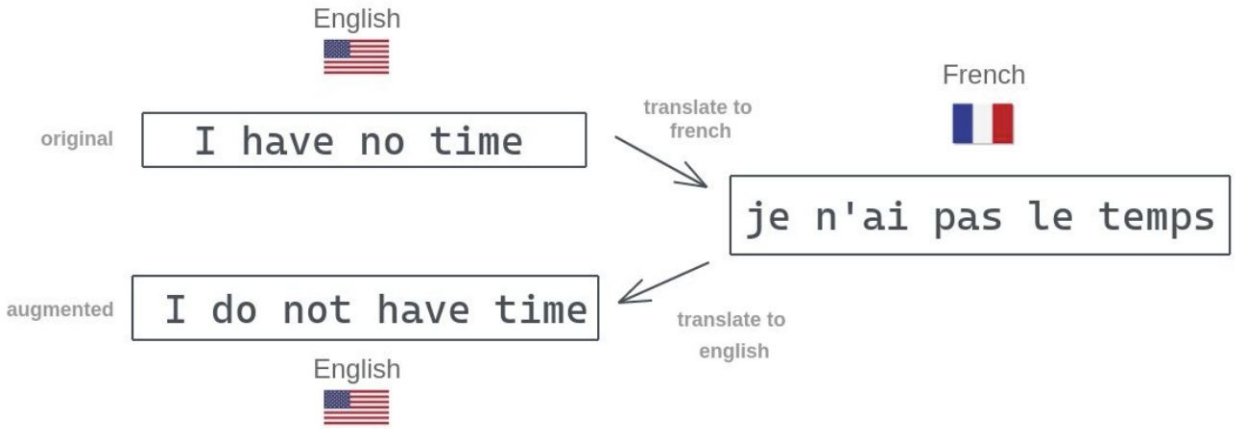

«Toxic Comment Classification Challenge»

Генерация синонимом

Один из самых простых способов - замена части слов на синонимы

«полуувядших лилий аромат мои мечтанья лёгкие туманит»
«полуувядших лилий запах мои мечтанья грудь туманит»

аромат	лёгкие
запах	грудь (1)
дух	дыхалка (1)
благоуханье	невесомые (2)

https://arxiv.org/pdf/1509.01626.pdf

Генерация синонимом

Данный способ замены использовался в статье Zhang et al. Character-level Convolutional Networks for Text Classification

Dataset	Classes	Train Samples	Test Samples	Epoch Size
AG's News	4	120,000	7,600	5,000
Sogou News	5	450,000	60,000	5,000

Генерация представлениями

Заменяем случайные слова на близкие по word embeddings

«полуувядших лилий аромат мои мечтанья лёгкие туманит»
«полуувядших лилий запах мои мечтанья лёгкие туманит»

аромат
запах 0.75
благоуханье 0.67
пряный 0.65
сладковатый 0.63

Генерация представлениями

Применялось в работе Wang and Yang

[«That’s So Annoying!!!: A Lexical and Frame-Semantic Embedding Based Data Augmentation Approach to Automatic Categorization of Annoying Behaviors using #petpeeve Tweets»]

Label	%	Label	%
appearance	.14	services	.02
disrespect	.06	traffic	.02
language	.06	advertisement	.01
hygiene	.05	bragging	.01
relationship	.05	children	.01
dishonesty	.03	complaining	.01
hypocrisy	.03	indolence	.01
incompetence	.03	physical	.01
interruption	.03	punctuality	.01
monetary	.03	racial	.01
sexual	.03	religious	.01
arrogance	.02	selfishness	.01
celebrity	.02	silence	.01
ignorance	.02	smoking	.01
privacy	.02	talkative	.01
products	.02	weather	.01

Распределение категорий твиттов

Генерация представлениями

Применялось в работе Wang and Yang

Methods	Prec.	Rec.	F1	Imp.
Lexical Baseline (No Data Augmentation)	.341	.342	.341	—
+ UrbanDictionary Embeddings	.343	.344	.344	0.9%
+ Twitter Embeddings*	.357	.358	.358	4.7%
+ GoogleNews Embeddings*	**.364**	**.366**	**.365**	**6.1%**

Таблица сравнения методов

Генерация с контекстом

Заменяем некоторые слова с помощью трансформера, обученного предсказывать пропущенное слово

Применялось в работе Garg. et al. «BAE: BERT-based Adversarial Examples for Text Classification»

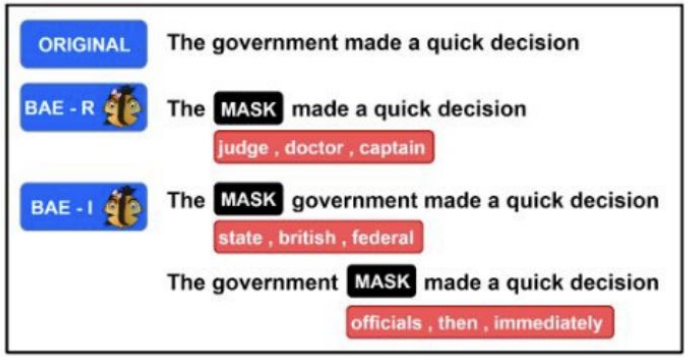

BAE-R – замена слова, BAE-I – добавление слова

Генерация текстовых данных

Метод	Когда использовать?
Замена синонимом	В текстах встречаются разнообразные слова, то есть самые разные синонимы могут подойти
Замена представлением	Тексты имеют определенную тематику, то есть подойдут синонимы из словаря соответствующей тематики
Замена контекстным представлением	Модель хорошо обучена для наших текстов

Академия
Аналитиков
Авито

Введение в LLM

avito.tech

Large Language Model

LLM - это статистическая модель, которая предсказывает следующий токен, основываясь на последовательности предыдущих токенов.

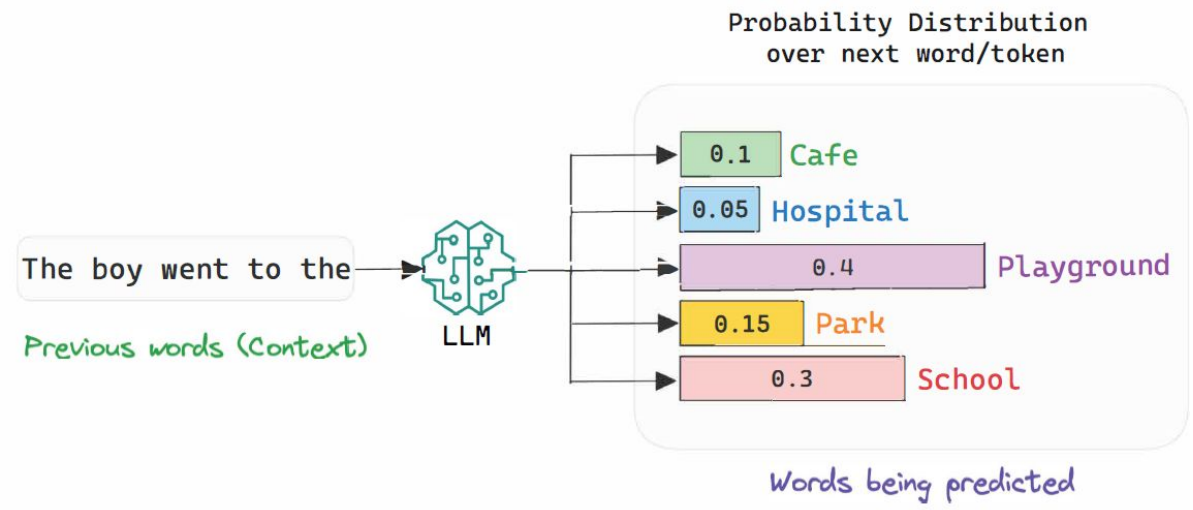

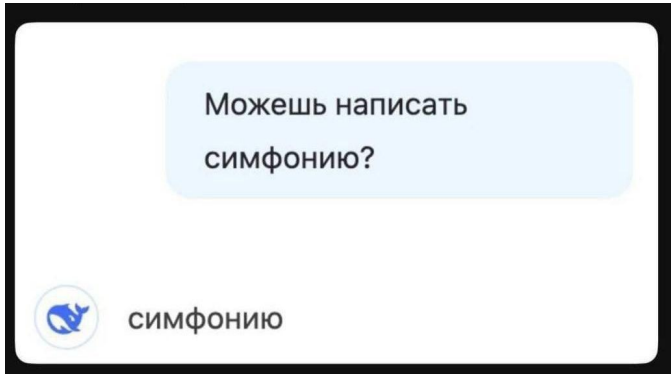

LLM inference

- Для генерации данных достаточно предсказывать по одному токену за раз
- Инференс в LLM - это процесс с множеством регулируемых параметров. Temperature определяет креативность текста, top-p и top-k контролируют разнообразие ответов, а repetition penalty помогает избежать повторений. Выбор оптимальных значений этих параметров зависит от специфики задачи: от строгого соответствия шаблону до творческой генерации

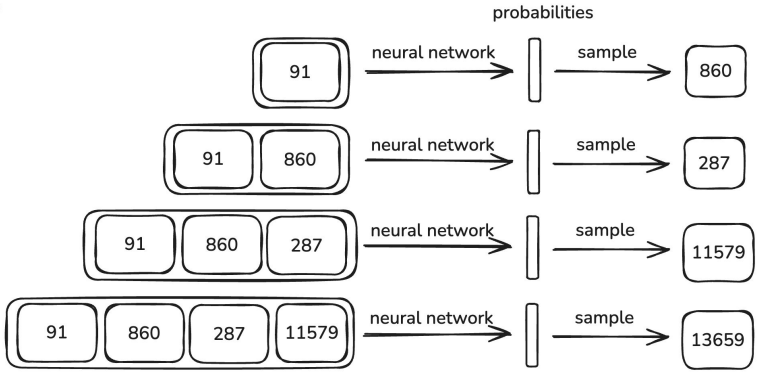

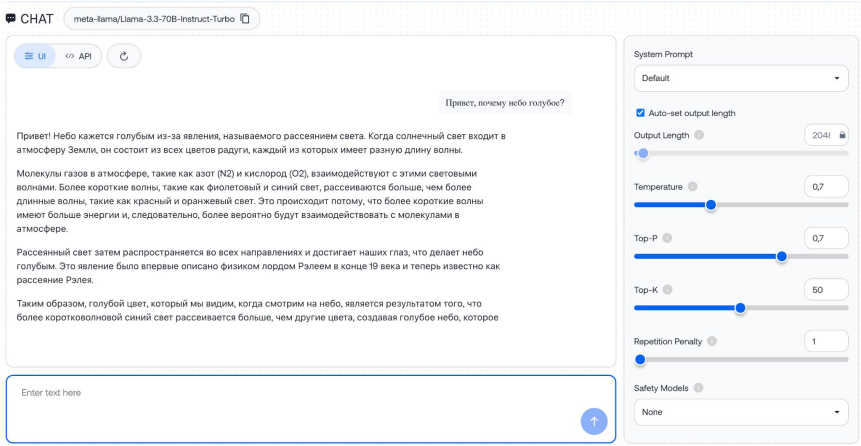

Тренировка LLM

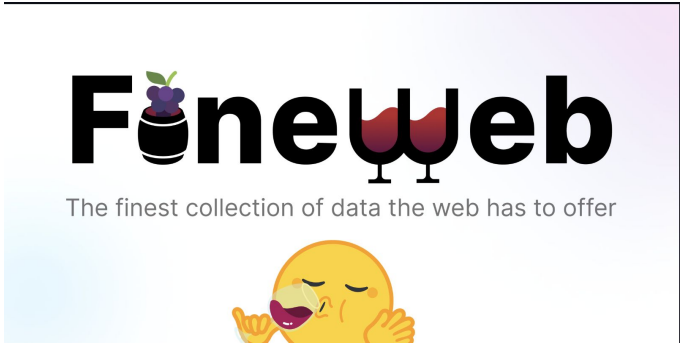

parameters.zip

Фрагмент всего интернета
~44 TB текста

16K GPUs, ~$20M, ~3.8e25FLOPS

~450 GB file

https://arxiv.org/pdf/2407.21783

Тренировка Ассистента

Step 1

Collect demonstration data, and train a supervised policy.

A prompt is sampled from our prompt dataset.

A labeler demonstrates the desired output behavior.

This data is used to fine-tune GPT-3 with supervised learning.

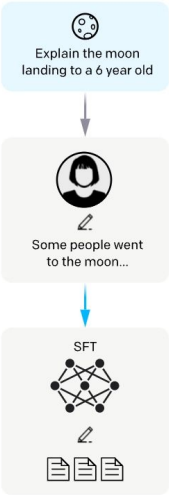

Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.

A labeler ranks the outputs from best to worst.

This data is used to train our reward model.

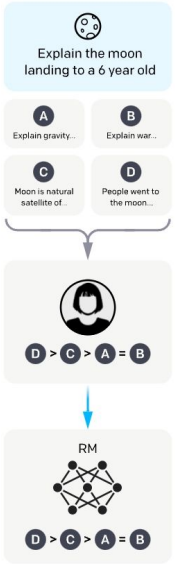

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.

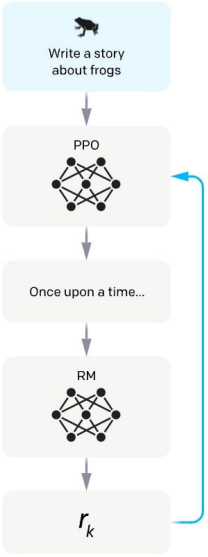

LLM токенизация

- Вход на llm - это последовательность номеров токенов от 0 до размера словаря
- Токенизация - важный элемент в обучении LLM. Токенизаторы для llm обучаются с помощью BPE.
- BPE (Byte Pair Encoding) - алгоритм, который находит часто встречающиеся сочетания символов в тексте и объединяет их в токены.

Token count
24

```
<|im_start|>system<|im_sep|>You are a helpful assistant<|im_end|><|im_start|>user<|im_sep|>Сколько букв r в слове Strawberry<|im_end|><|im_start|>assistant<|im_sep|>
```

```
200264, 17360, 200266, 3575, 553, 261, 10297, 29186, 200265, 200264, 1428, 200266, 3043, 96919, 125354, 428, 743, 30419, 327, 138322, 200265, 200264, 173781, 200266
```

LLM в авито

- Генерация описаний обьявлений
- Суммаризация чатов поддержки
- Извлечение параметров обьявлений
- Суммаризация отзывов
- Саджесты в мессенджере
- Саджесты агентам поддержки

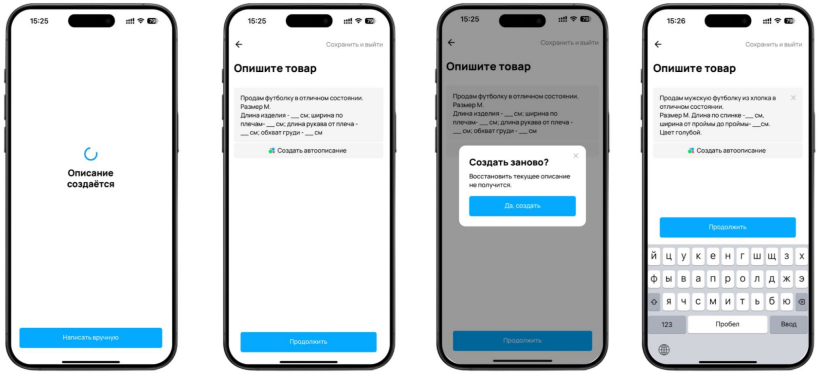

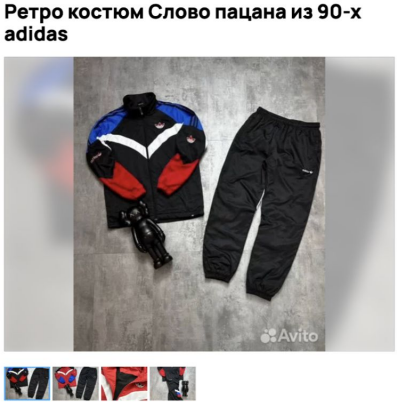

LLM нашла **Слово пацана**

Доклад LLM в авито

Подходы к дообучению LLM

- **Prompt Engineering**
  - Качество зависит от промта, но хуже чем в Prompt Tuning
  - Модель заморожена
  - От 0 до нескольких десятков примеров
- **Model Tuning**
  - Лучшее качество
  - Обучение всей модели
  - Десятки тысяч примеров
- **Prompt Tuning**
  - Хорошее качество
  - Обучаем только небольшой % весов
  - Сотни примеров

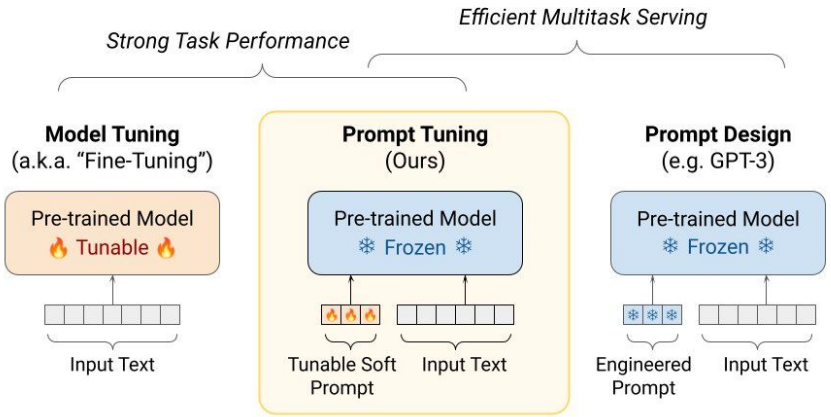

Prompt Tuning

- Вместо обучения всей модели, тюним только добавку непрерывных промптов
- P-tuning - одна из возможных реализация. В сочетании с дискретными промптами добавляем подводку эмбеддингов, которые будем обучать. Остальная модель заморожена.
- Моделировать эмбеддинги в P-tuning можно с помощью LSTM, MLP либо только эмбеддингами

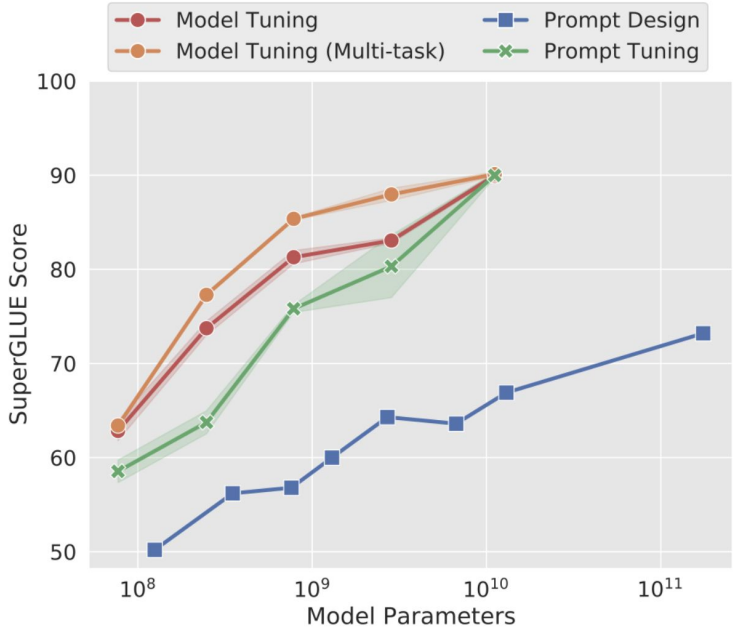

https://arxiv.org/pdf/2103.10385

Пример использования P-tuning в Авито

- SBERT - open-source модель
- prompts - подбираемые дискретные промпты
- prompts (distillation) - P-tuning подход
- mod-contacts-bert-model - дообученный берт на поиск контактов

	ROC-AUC	Average Precision
mod-contacts-bert-model	0.981	0.953
prompts (distillation)	0.970	0.927
prompts	0.922	0.814
SBERT(*)	0.897	0.788

Adapters

- Адаптеры - эффективный метод обучения
- Вместо обучения всей модели, добавляем небольшие обучаемые модули
- LoRA (Low-Rank Adaptation) - популярный тип адаптера. Обучаем две небольшие матрицы, которые будут добавкой к нашей основной матрице

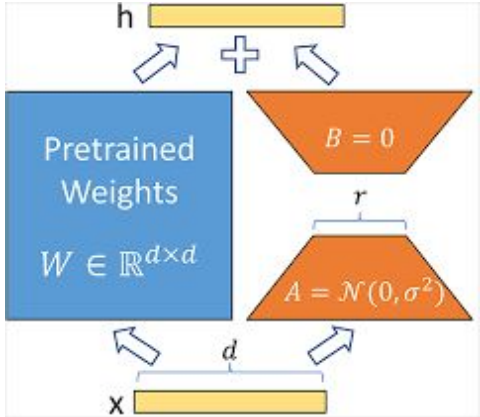

LoRA

Model&Method	# Trainable Parameters	WikiSQL Acc. (%)	MNLI-m Acc. (%)	SAMSum R1/R2/RL
GPT-3 (FT)	175,255.8M	**73.8**	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 ($Adapter^H$)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 ($Adapter^H$)	40.1M	73.2	**91.5**	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	**91.7**	**53.8/29.8/45.9**
GPT-3 (LoRA)	37.7M	**74.0**	**91.6**	53.4/29.2/45.1

https://arxiv.org/pdf/2106.09685

Академия
Аналитиков
Авито

Разметка с помощью промтов

Качество разметки LLM и краудсорсинга

- 2382 голден примеров, размеченных тренированными разметчиками
- zero shot ChatGPT-3.5 vs краудсорсеры с высоким рейтингом
- 5 разных задач на классификацию твитов
  - обсуждение политики модерации Твиттера (2 класса)
  - указывает ли твит на модерацию как на проблему (3 класса)
  - нарушающий закон США о контенте соц. сетей (3 класса)
  - классификация по проблемам (6 классов)
  - классификация по темам (14 классов)

Качество разметки LLM и краудсорсинга

- Модель на 4 из 5 задач справляется сопоставимо или лучше людей
- ChatGPT дешевле краудсорсинга

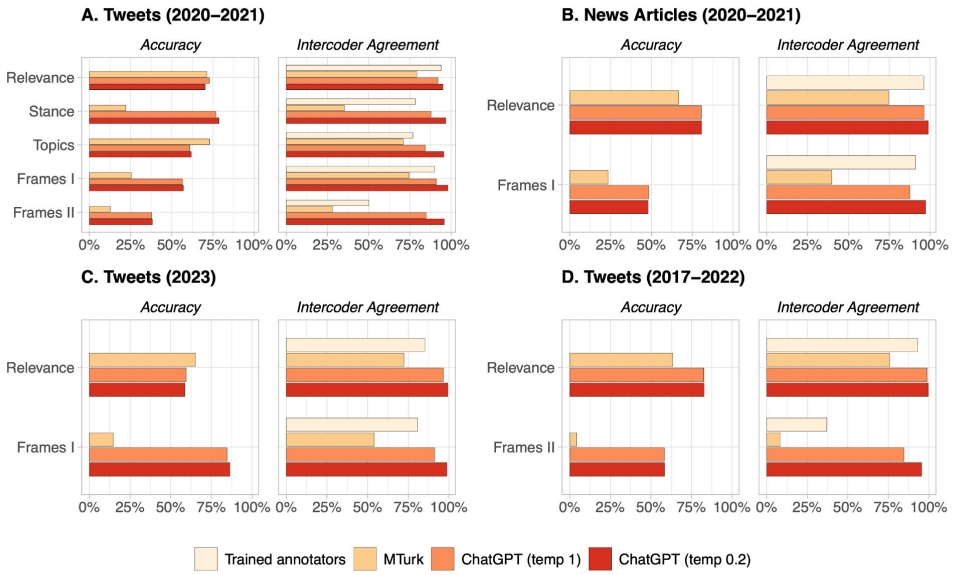

https://arxiv.org/abs/2303.15056

Качество разметки LLM и краудсорсинга

3 задачи:

- Датасет QK, оценка релевантности запроса пользователя в поисковике и ключевого слова (2 класса, BAD and NOT BAD)

- Boolean Questions, набор вопросов из поисковика, сопоставленных с параграфами из Википедии. Для каждого вопроса есть контекст, и по нему нужно ответить "ДА" или "НЕТ" (и ответ содержится в тексте)

- Word-in-Context, задача на устранение неоднозначности смыслов слов посредством бинарной классификации пар предложений. Даются два текстовых фрагмента вместе с многозначным словом, которое встречается в обоих предложениях. Ответ "ДА" если слово несёт один и тот же смысл в обоих контекстах, иначе "НЕТ”

https://arxiv.org/abs/2303.16854#

Качество разметки LLM и краудсорсинга

Размеры датасетов:

Task	Dev	Test
QK	350	1000
BoolQ	3270	3245
WiC	638	1400

Качество разметки LLM превосходит краудсорсинг

Task	Dev Set	Test Set
Crowdsourced Annotator	65.58	71.5
GPT-3.5 + prompts	74.17	75.60

QK task

Task	Dev Set	Test Set
Crowdsourced Annotator	80.0	80.0
GPT-3.5 + prompts	74.47	69.17

WiC task

Task	Dev Set	Test Set
Crowdsourced Annotator	89.0	89.0
GPT-3.5 + prompts	89.69	89.20

BoolQ task

Разметка LLM в Авито

- Необходимо определить категорию объявления по описанию (Тип верхней женской одежды)
- Размечаем датасет с помощью API ChatGPT
- Обучаем бертовую модель на разметке ChatGPT и на разметке пользователей

	Тест **chatGPT**	Тест **Пользователь**
Модель **chatGPT**	**98%**	91%
Модель **Пользователь**	93%	**94%**

Разметка LLM в авито

В авито есть инструмент для разметка dataset-collector

Преимущества авторазметки в dc:

- Хранение разметки в DWH
- Управление бюджетом
- Разметка воркером, то есть не нужно следить за отправкой и сбором ответы
- Большой выбор моделей

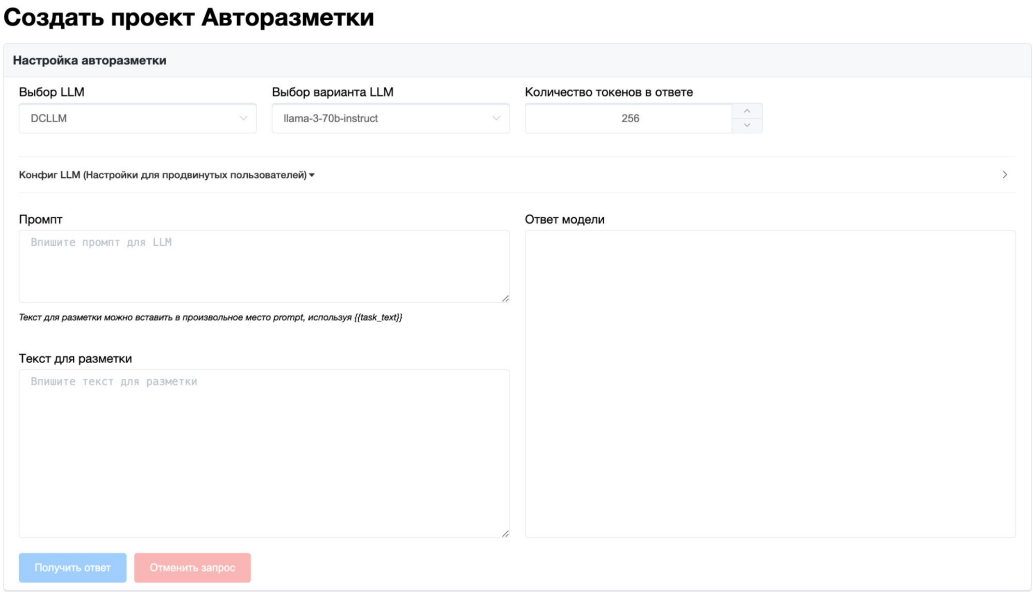

Разметка LLM в Авито

- Промпт это важно
- Голдены также нужны для LLM
- При хорошем промте GPT размечает как средний асессор
- GPT дешевле на порядок
- GPT размечает десятки тысяч заданий за час

	Ошибки	Глюки	Качество	Цена
Инструкция для разметки = промт				
Асессор 1	0.04		**0.96**	1,94 Р * 3
Асессор 2	0.03		**0.97**	
Асессор 3	0.11		**0.89**	
LLama	0.32	0.20	**0.49**	бесплатно
GPT-4o	0.12	0.03	**0.86**	0,35 Р
Корректировка промта				
LLama	0.08		**0.92**	бесплатно
GPT-4o	0.04		**0.96**	0,43 Р

Разметка LLM в Авито

- Разметка релевантности запроса и заголовка
- Разметка отзывов
- Разметка в матчинге
- Разметка задач классификации

Вы ассистент, который помогает анализировать отзывы. Ваша задача — определить, о какой проблеме идет речь в тексте отзыва, и выбрать одну из предложенных категорий. Если проблемы нет, это тоже нужно указать. Ответ должен быть только в формате одной из следующих категорий:

- "Несоответствие описанию"

- "Нет информации"

Примеры:

1. "Хотелось бы написать что как обычно все быстро и качественно, но в этот раз руль пришёл замятый и стойки руля меньшей высоты, чем в объявлении" → "Несоответствие описанию"

2. "Покупка прошла успешно, товар отличный" → "Нет информации"

3. "Не очень понятно, почему эти шлемы "для квадроцикла". Поздно распечатала коробку, увидела, что это обычный круглый мотошлем. Запах от него ужасный, технический - не проветривается совсем." → "Несоответствие описанию"

4. "Очень долго договаривались о доставке" → "Нет информации"

Отзыв: {{task_text}}

Релевантно ли объявление:
Название: %s
Описание: %s
Локация: %s

к запросу:
Текст: %s
Категория: %s?

Поставь оценку релевантности: 0, 1
Объявление должно полностью соответствовать запросу

Академия
Аналитиков
Авито

Практика prompt engineering

Академия
Аналитиков
Авито

Перерыв

10 минут